

Home Credit Default Risk Analysis

Python · DuckDB SQL · Tableau · scikit-learn

Мета: знайти сегменти клієнтів і патерни попередніх заявок, які пов'язані з підвищеним ризиком дефолту.

307K

клієнтів

application_train

8.07%

default rate

baseline

10

питань

research focus

Ключова теза

Найсильніші сигнали ризику з'являються не в одному факторі, а у комбінації: вік, фінансове навантаження та попередня кредитна історія.

Executive overview

02

Що було зроблено і який бізнес-сенс має аналіз

1 · Бізнес-питання

Які клієнти мають вищий ризик дефолту і які сигнали можуть допомогти в risk segmentation?

2 · Дані

307 511 поточних заявок + історія попередніх заявок тих самих клієнтів.

3 · Результат

Фінальні insights, SQL-запити, baseline ML і два Tableau dashboards.

Аналітичний workflow

01 Data prep

›

02 EDA

›

03 SQL

›

04 Hypothesis
+ ML

›

05 Tableau

Фокус презентації: не просто побудувати модель, а пояснити, які фактори формують ризик і як ці знання використати в бізнес-рішенні.

Дані та технологічний стек

03

Дві основні таблиці, підготовка ознак і окремий шар для Tableau

Dataset: Kaggle Home Credit

`application_train.csv`

Поточні кредитні заявки, характеристики клієнтів і цільова змінна TARGET.

`previous_application.csv`

Історичні заявки тих самих клієнтів: статус, тип продукту, запитана та погоджена сума.

Сирі дані не включені в репозиторій через розмір і правила Kaggle.

Tech stack

- **Python 3.12** EDA, cleaning, modeling
- **pandas / numpy** data manipulation
- **DuckDB SQL** аналітичні запити
- **statsmodels** перевірка гіпотез
- **scikit-learn** baseline ML
- **Tableau Public** дашборди

Data preparation: підготовка аналітичного шару

04

Ключовий етап перед сегментацією та побудовою моделі

Завантаження та огляд структури

Перевірка типів колонок, пропусків, спеціальних значень (XNA, 365243) та розподілу TARGET.


Аналітичні ознаки

age_years · employment_years · credit_income_ratio · annuity_income_ratio

Групи для сегментації

age_group · credit_income_group · previous_applications_group · offer_gap_group → готово для Tableau


Outlier check: фінансові показники



Baseline risk: default rate = 8.07%

05

Перший важливий висновок - задача має сильний дисбаланс класів



307 511

кредитних заявок у
базовій таблиці

24 825

клієнтів із TARGET = 1

91.93%

клас No default

Чому це важливо для моделі?


Ассурасу може бути оманливо високою: модель, яка майже завжди прогнозує “No default”, вже отримає близько 92% ассурасу. Тому для дефолту важливі Recall, Precision, F1-score та ROC-AUC.

Key message: оцінюємо не лише accuracy

Клієнтські сегменти: де ризик вищий за baseline

06

Сегментація дає зрозуміліші бізнес-патерни, ніж середнє по всій вибірці



Пунктир - загальний default rate 8.07%

11.47%

вік 20-29

+3.4 pp до baseline

10.93%

Lower secondary

за рівнем освіти

Інтерпретація

Вік 20–29 — найпомітніший демографічний сигнал. Це не означає автоматичну відмову, але сегмент потребує уважнішого risk review, особливо разом із фінансовим навантаженням та історією попередніх заявок.

Business use


Використовувати сегменти не як самостійні правила скорингу, а як додаткові flags у risk segmentation.

Фінансове навантаження: ризик не зростає лінійно

07

Credit-to-income ratio = сума кредиту / річний дохід клієнта

Групи показують, у скільки разів сума кредиту перевищує річний дохід: 2–3х = кредит у 2–3 рази більший за річний дохід.



Найвищі значення у групах 2-3х та 3-5х

8.69%

група 2-3х

вище baseline

8.77%

група 3-5х

вище baseline

Головний висновок

Найризиковішим виявилось середнє кредитне навантаження, а не максимальне. Це може означати різний профіль клієнтів у крайніх групах.

Рекомендація


Використовувати ratio-показники, а не лише абсолютні суми кредиту чи доходу.

Попередні заявки: історія клієнта - додатковий сигнал ризику

08

Refused status i revolving products пов'язані з вищим default rate

Default rate by previous application status



Previous status = Refused має найвищий default rate

12.0%

previous status = Refused

10.47%


previous Revolving loans

11.2%

Refused + Revolving

Default Rate by Refused History and Revolving Product

Darker color = higher default rate



Комбінація Refused + Revolving = 11.2%

Важливо: 12.0% - зріз за статусом попередньої заявки;
10.3% - клієнтський flag "має хоча б одну refused заявку".

SQL validation layer: DuckDB-запити для Tableau

09

SQL-запити для валідації патернів та підготовки агрегованих даних для Tableau

```
q01_default_rate_by_credit_income_group.sql
```

Сегменти за кредитно-дохідним навантаженням

Порівняння Default Rate по групах фінансового навантаження — визначення зони підвищеного ризику.

Insight: найвищий Default Rate у групах 2–3х та 3–5х.

```
q02_default_rate_by_previous_applications_count.sql
```

Кількість попередніх заявок

Перевірка: чи пов'язана більша кількість попередніх заявок із вищим ризиком дефолту.

Insight: клієнти з 6+ попередніми заявками мають вищий Default Rate, ніж клієнти без попередніх заявок.

```
q03_default_rate_by_previous_status_and_product_type.sql
```

Статус × тип продукту попередніх заявок

Визначення найризиковіших комбінацій статусу та типу контракту попередніх заявок.

Insight: найризиковіша комбінація — Refused + Revolving, Default Rate 11.2%.

Гіпотези та аналітичні знахідки

10

Окремо відділяємо статистично підтверджене від exploratory signals

Фактор	Порівняння	Статус	Що це означає
Вік 20-29	11.5% vs 8.07%	Observed pattern	Найвищий демографічний ризик
Credit-to-income 2-3x / 3-5x	8.7-8.8%	Observed pattern	Середнє навантаження - зона ризику
Previous refused applications	10.3% vs 7.0%	Statistically supported	Сильний додатковий risk flag
Previous revolving loans	9.5% vs 7.3%	Observed pattern	Потребує окремого risk review
Offer gap	8.1% vs 6.7%	Exploratory	Слабкий сигнал, не standalone rule
Refused + revolving	11.2%	Observed pattern	Найризиковіша комбінація

Ці результати використовуються для risk segmentation та бізнес-інтерпретації, а не як готові scoring rules.

Baseline ML: модель показала головне обмеження

11

Logistic Regression використана як точка відліку, не як production scoring model

Ознаки мають потенційний предиктивний сигнал

Вік, credit-to-income ratio та попередні заявки мають потенційний предиктивний сигнал — це узгоджується з EDA.


Дисбаланс класів - головна проблема

Default class = 8.07%. Baseline модель схильна прогнозувати клас більшості, тому recall для default потребує покращення.

Що робити далі

SMOTE або class_weight, зміна threshold, порівняння Logistic Regression із LightGBM / Random Forest.

ML висновок: спочатку балансування, потім оцінка якості



Модель прогнозує лише No default - наочний ефект дисбалансу класів

Tableau dashboards: фінальна бізнес-візуалізація


12

Два інтерактивні dashboards для огляду ризику і previous application impact

Client Risk Overview

Home Credit Default Risk | 307 511 clients | Kaggle dataset

Key insight: The highest default risk is observed among clients aged 20-29 (11.5%) and credit-to-income ratio groups 2-3x / 3-5x.




Client Risk Overview: вік, credit-to-income, освіта, фільтри

Previous Applications Impact

Client default risk by previous applications, refused history, revolving products and offer gap

Key insight: Previous credit history matters — clients with refused applications or revolving loans tend to have higher default risk



Previous Applications Impact: refused, revolving, offer gap, count

Tableau Public: Liudmyla Sibikovska

Бізнес-рекомендації

13

Як використати результати для risk segmentation

01 Risk flags

Додати previous refused applications як окремий flag для risk review.

02 Financial load KPI

Регулярно відстежувати credit-to-income ratio 2-3x та 3-5x.

03 Young clients

Для 20-29 років поєднувати вік із фінансовим навантаженням та історією заявок.

04 Revolving history

Окремо моніторити клієнтів із previous revolving loans.

05 Combined segmentation

Не приймати рішення за одним фактором: комбінувати демографію, фінанси та previous apps.

06 ML improvement

Працювати з class imbalance перед використанням моделі для default detection.

Рекомендації не є автоматичними правилами відмови - це напрями для сегментації, моніторингу і наступних моделей.

Що покращити в наступній ітерації

14

Аналітика вже дає segmentation insight, але модель потребує розвитку

01 Class imbalance

SMOTE / class_weight /
threshold tuning для
покращення Recall дефолту.

02 More features

Додати bureau, installments,
credit_card_balance,
POS_CASH_balance.

03 Model benchmark

Порівняти Logistic
Regression з LightGBM або
Random Forest.

04 Time patterns

Дослідити зміну ризику в часі та залежність від
економічних циклів.

05 Dashboard refresh

Налаштувати регулярне оновлення Tableau для
актуальної структури портфеля.

Final note

Проект демонструє повний цикл:
підготовка даних -> аналітичні висновки -> SQL validation -> baseline ML -> Tableau dashboards -> бізнес-рекомендації.

Дякую!

Home Credit Default Risk Analysis

GitHub: github.com/Liudmyla-D/home-credit-default-risk

Tableau Public: Liudmyla Sibikovska

Коротко про цінність

Аналіз допомагає перейти від загального default rate до зрозумілих сегментів ризику та напрямів покращення скорингової логіки.